上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

SJTU

第2讲

科研伦理与 Agent 边界

饮 水 思 源 • 爱 国 荣 校

第 1 讲回顾：知识与产物

把 AI 建议变成可检查的项目修改

知识点

核验输出与结论成立条件

由研究者决定
采纳、修改或拒绝

用八阶段定位动作与下一步

核心产物

一处人工认可的问题修改

与修改对应的 diff

一条含理由与核验的使用记录

当前不确定性及其阶段位置

打开第 1 讲修改与日志样例

从 diff 与日志到材料、动作和责任

第 1 课的记录，还需要补什么？

材料	输入是否获得授权，来源是什么？
动作	只读、写入、执行，还是对外发送？
确认	哪一步需要暂停，由谁决定继续？
责任	实际发生了什么，由谁核验和承担？

声明与 trace 的缺口

READ 仅 problem-definition.md；WRITE 仅获批段；NETWORK off

E3｜批准建议 B
E4｜helper 读取 notes/source-list.md
E5｜diff 只含获批段

diff 合规，能否据此接收“全部权限通过”？指出应暂停的位置。

来源：本课判断任务与讲义；构造材料及真实来源按材料包标识

科研诚信的六项价值

NASEM · Fostering Integrity in Research · 2017

Report

April 2017

HIGHLIGHTS

Fostering Integrity in Research

The scientific research enterprise is a cornerstone of modern society. The U.S. public- and private-sector investment in research delivers enormous benefits to society in the form of better health, enhanced understanding of the natural world, and new technologies that boost economic growth and improve life in myriad ways. The integrity of knowledge that emerges from research is based on individual and collective adherence to core values of objectivity, honesty, openness, fairness, accountability, and stewardship.

Fostering Integrity in Research, a report from the National Academies of Sciences,



客观 objectivity

诚实 honesty

开放 openness

公平 fairness

问责 accountability

守护责任 stewardship

一次 Agent 动作，可能损害其中哪项价值?

中科院与交大的制度依据

中国科学院 · 2024

《科研活动 AI 诚信提醒》



中国科学院发布《关于在科研活动中规范使用人工智能技术的诚信提醒》

2024-09-11　来源：监督与审计局　【字体：大 中 小】　语音播报

9月10日，中国科学院科研道德委员会公开发布《关于在科研活动中规范使用人工智能技术的诚信提醒》（以下简称《诚信提醒》），对中国科学院科技人员和学生进行提醒。

近年来，人工智能技术的快速发展与广泛应用，给科学研究带来了新的变革与创新，同时也对支撑科研诚信的现有实践提出了严峻挑战。譬如，利用人工智能算法伪造数据，生成欺骗性研究论文，极易引发新形式的论文代写、抄袭剽窃、洗稿等学术不端行为，极大损害了科学研究的可信度。

《诚信提醒》由中国科学院科研道德委员会组织院内外专家，聚焦人工智能技术在科研活动全流程应用中可能存在的问题与挑战，经深入讨论研究、广泛征求意见后形成，共八条。

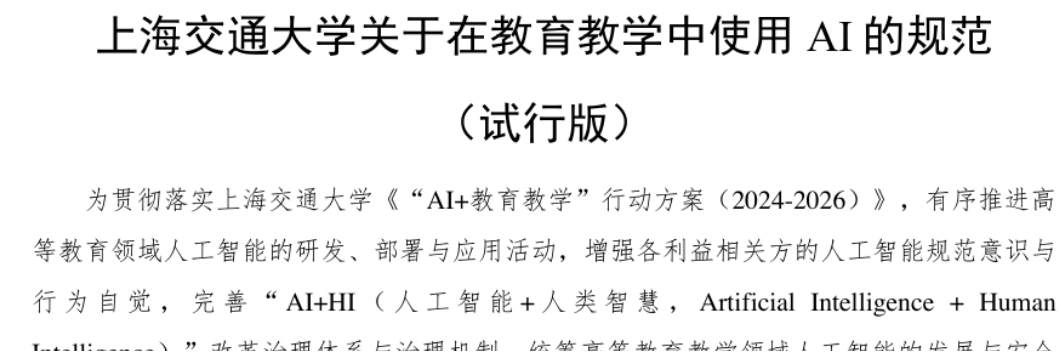
科研活动中的诚信要求

核验与披露 AI 使用

保护数据和未公开材料

上海交通大学 · 试行版

《教育教学中使用 AI 的规范》



上海交通大学关于在教育教学中使用 AI 的规范

（试行版）

为贯彻落实上海交通大学《“AI+教育教学”行动方案（2024-2026）》，有序推进高等教育领域人工智能的研发、部署与应用活动，增强各利益相关方的人工智能规范意识与行为自觉，完善“AI+HI（人工智能+人类智慧，Artificial Intelligence + Human Intelligence）”改革治理体系与治理机制，依等高等教育教学领域人工智能的发展与安全

教育教学场景的分类治理

禁止使用 / 有限使用

鼓励使用 / 开放使用

合作稿：输入与处理环境

同一研究目标：梳理研究问题与相关线索

当前路径

合作原稿

缺少发送授权
平台条款未核对

暂停外发

可继续的路径

确认输入与环境 → **AI 辅助讨论** → **研究者核验**

获准讨论的问题描述
符合要求的处理环境

研究问题与相关线索

检查依据
记录取舍

先确认可讨论内容与处理环境，再决定是否发送。

一张可检查的风险记录

课堂构造填写示例 · 未公开合作稿

字段	具体内容
对象 Asset	未公开的共同作者工作稿
动作 Action	上传到个人账户下的外部模型
风险 Risk	合作内容暴露，保密与知识产权风险
控制 Control	暂停原稿外发，确认获准输入与处理环境
责任 Owner	共同作者决定材料授权，使用者核查执行边界

允许、有条件允许与禁止

处置	具体动作	决定性理由
允许	用获准的问题描述 讨论研究问题与线索	输入与环境条件已确认 研究者核验与记录取舍
有条件允许	在本地只读分析 经授权的数据	先完成必要脱敏 限定目录，禁止外传
禁止	把模拟数据 写成真实实验观测	材料身份被冒充 结论失去事实依据

同一项 AI 能力，处置取决于具体任务条件。

发送未公开材料前的五项检查

材料身份	作者工作稿，还是负有保密义务的评审稿?
权利与同意	共同作者、数据主体及权利方是否同意?
适用规则	机构、项目、期刊是否提出更严格要求?
使用环境	存储、训练使用与访问权限是否可接受?
最小必要	能否改用抽象问题或更少的获准片段?

课内练习使用公开、课堂构造或已授权脱敏材料。

未获授权材料外发后的处理

先停止进一步发送，保留可核对的记录

停止扩散	暂停后续发送与共享
评估范围	核对输入片段、敏感程度与接收环境
记录事实	保存工具、时间、材料范围与实际动作
按要求沟通	依机构或合作约定处理，并改用合规输入

模拟数据与真实观测的结论边界

材料身份	可用于	能够支持	不能据此声称
模拟数据 显式标注	检查代码 异常处理 统计流程	程序通过了 所设模拟条件 下的检查	真实人群有效 真实实验成立
真实实验 观测数据	按授权协议 整理和分析 实际结果	本样本、设计 与测量条件下 观察到的结果	所有场景通用 未经设计支持 的因果结论

检查一句结论：它是否超出了材料能够支持的范围？

批准必须落实为协议变更

课堂构造的失败情境：看到结果后更换主指标

只有一句“同意修改”

旧协议被覆盖

更换理由没有留下

只报告新指标的好结果

可核对的协议修订

保留	原主指标与原结果
说明	变更动机和适用范围
写回	新旧协议差异与批准记录
报告	区分原定分析与事后分析

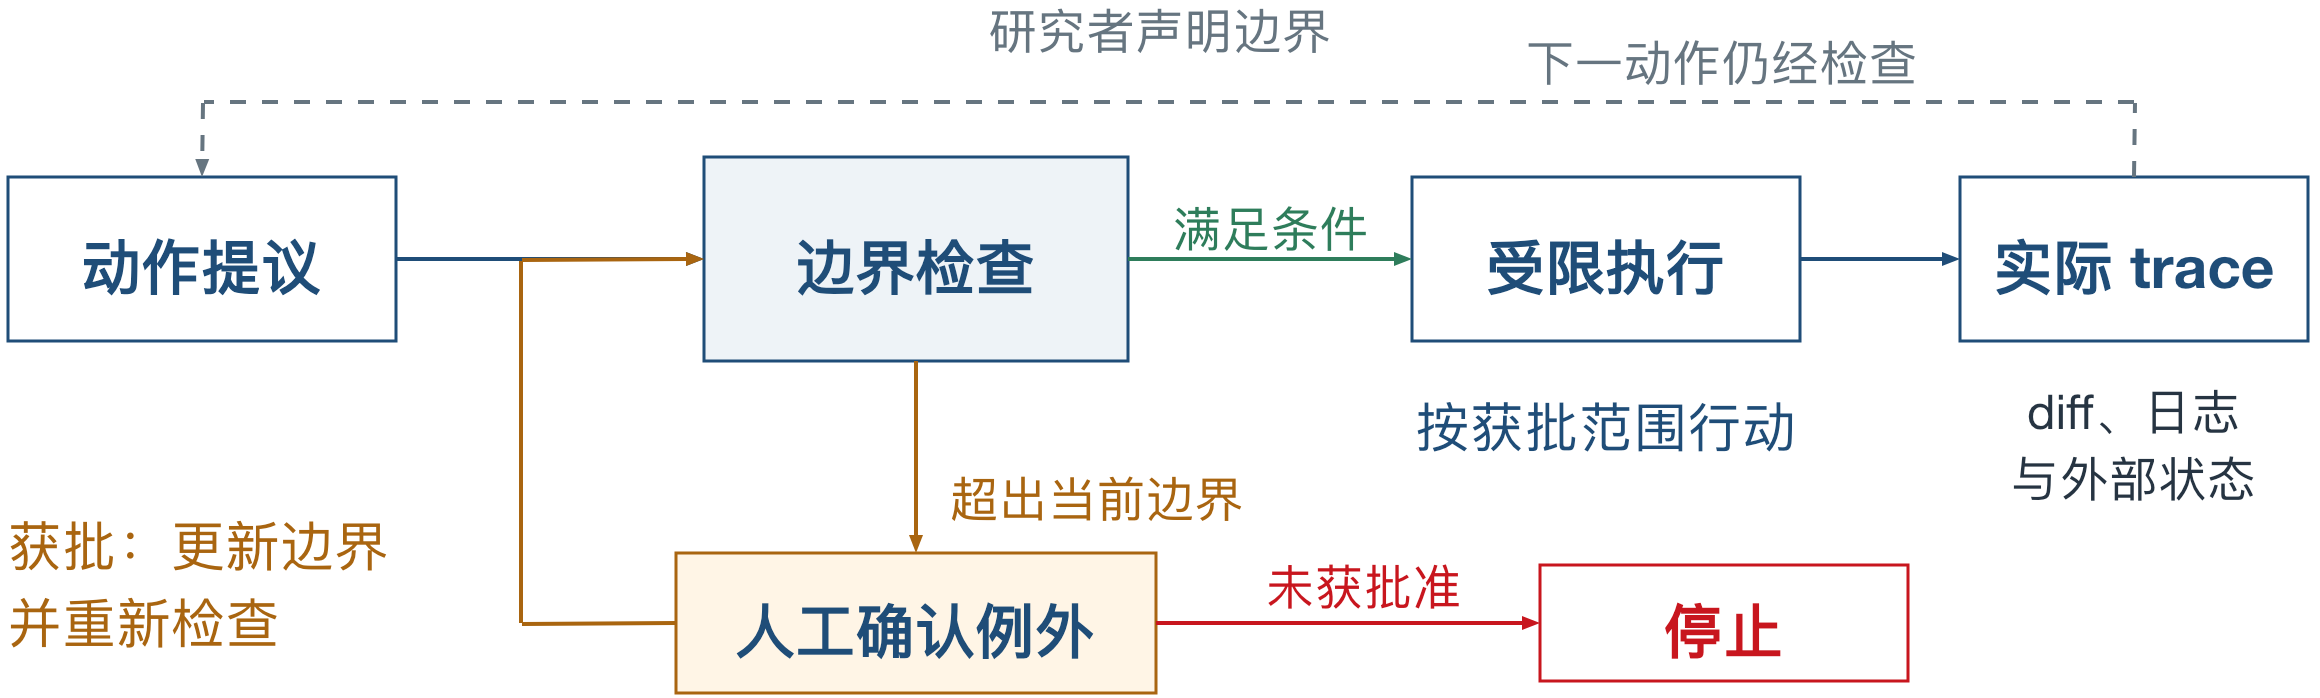
研究 harness：把边界落实到每一步

研究协议

目标、指标、停止条件

任务权限

可读、可写、可执行



默认拒绝与最小权限

默认拒绝

没有明确授权的动作
先停在检查点。

例如：联网、外发、额外写入

最小权限

为当前任务开放
刚好足够的范围。

具体到文件、段落与动作

任务或动作变化后，重新检查授权。

权限矩阵：先写清一次任务授权

课堂构造案例

输入获准，处理环境条件已确认

对象或能力	只读范围	可写范围	是否允许执行	人工确认点	禁止事项
合作稿的 替代输入	获准讨论的 问题描述	权限一行 风险卡 使用记录	本次不运行 命令、不联网	写回前确认 文件、段落 与修改范围	读取或外发 未公开原稿； 改问题或指标

写回前，具体要确认什么？

目标文件、目标段落与修改范围

过宽授权与任务授权

课堂构造配置

过宽授权

READ　整个用户目录

WRITE　任意文件

RUN　任意命令

NETWORK on

CONFIRM 完成后告知

任务授权

READ　指定的公开材料

WRITE　获批文件与段落

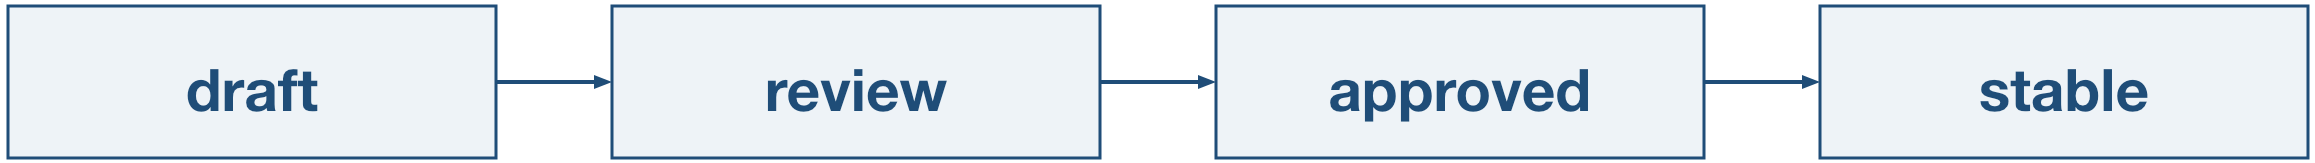
RUN　本次不执行命令

NETWORK off

CONFIRM 写回前确认范围

先找到过宽范围，再说出怎样收窄。

工件状态与证据成熟度



草稿与待查缺口

已有依据
进入复核

关键决策获批
边界与理由已记录

至少两项独立证据
边界可追溯

状态可以回退



一份证据地图的状态迁移

evidence-map.md

状态	这次新增什么	复核依据	支持下游动作
draft	候选来源与缺口	保留待核验标记	设计检索计划
review	原文位置与冲突	自查、同伴复核	修订问题定义
approved	问题门通过条件	判断理由与 diff	形成实验规格
stable	独立证据与边界	结论可追溯复核	支撑最终论证

“写完了”只说明编辑结束，状态迁移还需要依据。

一条 AI 使用记录应说明什么

课堂构造记录 · 合作稿的替代输入

字段	可核对的记录内容
步骤与 Context	生成候选检索词，只输入人工抽象问题。
AI 输出	给出候选词及对应的检索方向。
人的决定	保留与研究对象一致的词，删除过宽概念。
核验方法	逐项对照原问题，记录保留和删除的理由。

若未调用模型，记录“未执行”及实际人工检查。

助教演示：风险与权限如何落地

助教演示 · 同一未公开合作稿案例

输入与环境 → **只读边界审查** → **人工确认写回** → **核对三件工件**

仅用获准问题描述
处理环境已确认

检查过宽权限
与缺失的确认点

明确三份文件
及各自修改范围

风险卡、权限行
使用记录相互一致

第一轮：只读边界审查

助教演示 · 任务契约

第一轮

READ　agent-permissions.md

TASK　指出一处过宽或缺失权限

WRITE　none

NETWORK off

RETURN　建议、风险与最小替代动作

STOP　等待人工确认

研究者检查

建议收窄了范围，
还是隐含扩大了
读写与外发权限?

第二轮：批准后的三处写回

助教演示 · 任务契约

第二轮：只写回获批范围

WRITE　agent-permissions.md 一行

　　ethics-and-compliance.md 风险卡

　　ai-usage-log.md 一条记录

KEEP　问题、指标与工件状态

NETWORK off

AFTER　展示实际 diff

确认点

文件

段落

修改范围

本人项目：决定、核验与回写

给本人一个动作写清读写范围、确认点与拒绝分支，更新既有权限行、风险卡和日志。选一次允许动作和一次越界尝试检验控制。

用现有 access-check
接口或人工逐步拦截演示拒绝；如仅验证接口，记录“非操作系统隔离”。未获授权的读取不要真实执行。

保存：权限行、风险卡、一次允许/拒绝检查及日志

来源：本课判断任务与讲义；构造材料及真实来源按材料包标识

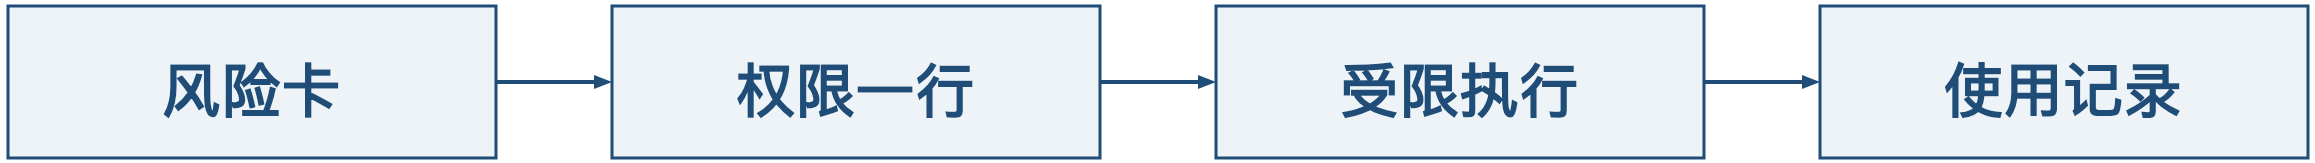
临时结对：三件工件是否一致

把风险卡、权限行和使用记录放在一起

同一输入	三处写的材料对象和授权状态是否一致?
同一动作	权限允许的范围是否覆盖实际行动?
可操作确认	能否明确何时停下、由谁确认什么?
作者决定	记录采纳、修改或拒绝，以及理由。

本讲知识点总结

给一个具体动作留下完整的约束与记录



为什么需要控制?　　什么范围可执行?　　每一步检查边界　　实际做了什么?

研究者对材料、决定与最终使用承担责任。

保留本课决定，准备下一课输入

L3 只在已声明的公开来源和网络范围内检索。

回写已有项目：权限行、风险卡、一次允许/拒绝检查及日志

只读指定段落，补课堂留下的真实缺口。安装与排障计入课外总预算。

来源：本课判断任务与讲义；构造材料及真实来源按材料包标识